

ANNEE

On suppose que $f=0$

POPULATION TOTAL : $n=2048 \Rightarrow 2n=4096$

Alors on compte les allèles :

$$\begin{cases} f(G1) = 2 \cdot 128 + 196 + 929 = 881 \\ f(G2) = 196 + 2 \cdot 173 + 513 = 1055 \\ f(G3) = 929 + 513 + 2 \cdot 609 = 2160 \end{cases}$$

Donc les fréquences allélique :

$$\begin{cases} p_1 = 881/4096 \approx 0,215 \\ p_2 = 1055/4096 \approx 0,258 \\ p_3 = 2160/4096 \approx 0,527 \end{cases}$$

Alors

$$\begin{cases} p(G3G3) = p_1^2 \approx 0,046 \\ p(G3G3) = 2p_1p_2 \approx 0,111 \\ p(G3G3) = 2p_1p_3 \approx 0,227 \\ p(G3G3) = p_2^2 \approx 0,066 \\ p(G3G3) = 2p_2p_3 \approx 0,272 \\ p(G3G3) = p_3^2 \approx 0,278 \end{cases}$$

Donc les effectifs attendus sont

	ATTENDU	
G1G1	$\approx 94,75$	$= n \cdot p(G1G1)$
G1G2	$\approx 226,92$	$= n \cdot p(G1G2)$
G1G3	$\approx 964,59$	$= n \cdot p(G1G3)$
G2G2	$\approx 135,87$	$= n \cdot p(G2G2)$
G2G3	$\approx 556,35$	$= n \cdot p(G2G3)$
G3G3	$\approx 569,53$	$= n \cdot p(G3G3)$

Donc si on regarde

$$\text{HOMOZYGOTES} = \sum_i n p(G_i G_i) = 910$$

$$\text{HOMOZYGOTES}_{HW} = \sum_i n p(G_i G_i | \text{attendu}) = 800,14$$

On suppose $f \neq 0$

On prend l'événement:

C : les allèles viennent du même ancêtre $\Rightarrow P(C) = f$

$\bar{C}$: les allèles ne viennent pas du même ancêtre $\Rightarrow P(\bar{C}) = 1 - f$

Alors on a:

$$\begin{aligned} * \text{ HOMozyGOTE} \quad P(G_i G_i) &= P(G_i G_i | C) P(C) + P(G_i G_i | \bar{C}) P(\bar{C}) \\ &= p_i \cdot f + p_i^2 \cdot (1 - f) \end{aligned}$$

Par

la mère transmet G_i avec proba p_i et le père transmet G_i avec proba p_i $\Rightarrow P(G_i G_i | \bar{C}) = p_i^2$
de même ancêtre distribue la G_i avec proba p_i $\Rightarrow P(G_i G_i | C) = p_i$

$$\begin{aligned} * \text{ HÉTÉROzyGOTE: } P(G_i G_j) &= P(G_i G_j | C) P(C) + P(G_i G_j | \bar{C}) P(\bar{C}) \\ &= 0 \cdot f + 2 p_i p_j \cdot (1 - f) \end{aligned}$$

Par

la mère transmet G_i avec proba p_i et le père transmet G_j avec proba p_j $\Rightarrow P(G_i G_j | \bar{C}) = 2 \cdot p_i p_j$
le père transmet G_i avec proba p_i et la mère transmet G_j avec proba p_j

Pas possible d'être consanguin $\Rightarrow P(G_i G_j | C) = 0$

Avec le tout, on a que:

$$\begin{aligned} P(\text{homozygote}) &= \sum_i P(G_i G_i) = \sum_i p_i f + p_i^2 (1 - f) \\ P(\text{hétérozygote}) &= \sum_{i < j} P(G_i G_j) = \sum_{i < j} 2 p_i p_j (1 - f) \end{aligned}$$

Donc on peut construire la vraisemblance pour les données observées:

$$\begin{aligned} L(f, p_1, p_2, p_3) &= \prod_i P(G_i G_i)^{n_{ii}} \prod_{i < j} P(G_i G_j)^{n_{ij}} \\ &= \prod_i (f p_i + (1 - f) p_i^2)^{n_{ii}} \prod_{i < j} (2 (1 - f) p_i p_j)^{n_{ij}} \end{aligned}$$

Avec le passage à la log-vraisemblance :

$$\begin{aligned} l(\phi, t_1, t_2, t_3) &= \sum_i m_{ii} \log [\phi t_i + (1-\phi) t_i^2] + \sum_{i \neq j} m_{ij} \log [2(1-\phi) t_i t_j] \\ &= \sum_i m_{ii} \log [\phi t_i + (1-\phi) t_i^2] + \sum_{i \neq j} m_{ij} (\log [2] + \log [(1-\phi) t_i t_j]) \\ &= \sum_i m_{ii} \log [\phi t_i + (1-\phi) t_i^2] + \sum_{i \neq j} m_{ij} \log [(1-\phi) t_i t_j] + \underbrace{\sum_{i \neq j} m_{ij} \log [2]}_K \end{aligned}$$

On veut continuer la vraisemblance avec les données complètes

On peut composer $m_{ii} = m_{ii}^c + m_{ii}^{\bar{c}}$


On a :

$$P(c, G_i G_i) = P(c) P(G_i G_i | c) = \phi \cdot t_i$$

$$P(\bar{c}, G_i G_i) = P(\bar{c}) P(G_i G_i | \bar{c}) = (1-\phi) \cdot t_i$$

Donc on peut écrire la vraisemblance

$$\begin{aligned} L_c(\phi, t_1, t_2, t_3) &= \prod_i P^{m_{ii}^c}(c, G_i G_i) P^{m_{ii}^{\bar{c}}}(c, G_i G_i) \prod_{i \neq j} P^{m_{ij}}(G_i G_j) \\ &= \prod_i (\phi t_i)^{m_{ii}^c} ((1-\phi) t_i)^{m_{ii}^{\bar{c}}} \prod_{i \neq j} (2(1-\phi) t_i t_j)^{m_{ij}} \end{aligned}$$

Donc la log-vraisemblance est :

$$\begin{aligned} l_c(\phi, t_1, t_2, t_3) &= \sum_i m_{ii}^c \log [\phi t_i] + \sum_i m_{ii}^{\bar{c}} \log [(1-\phi) t_i] + \sum_{i \neq j} m_{ij} \log [(1-\phi) t_i t_j] \\ &\quad + \underbrace{\sum_{i \neq j} m_{ij} \log [2]}_K \end{aligned}$$

ÉTAPE E: calcul des espérances de m_{ii}^c et $m_{ii}^{\bar{c}}$

On a:

$$P(C) = f \quad \text{et} \quad P(\bar{C}) = 1 - f$$

$$P(G_i G_i | C) = f_i \quad \text{et} \quad P(G_i G_i | \bar{C}) = f_i^2$$

$$P(C, G_i G_i) = f f_i \quad \text{et} \quad P(\bar{C}, G_i G_i) = (1 - f) f_i^2$$

$$P(G_i G_i) = f f_i + (1 - f) f_i^2$$

Donc la probabilité de observer C si on connaît $G_i G_i$

$$P(C | G_i G_i) = \frac{P(C, G_i G_i)}{P(G_i G_i)} = \frac{f f_i}{f f_i + (1 - f) f_i^2}$$

Donc

$$\begin{cases} E[m_{ii}^c] = \hat{m}_{ii}^c = m_{ii} P(C | G_i G_i) \\ E[m_{ii}^{\bar{c}}] = \hat{m}_{ii}^{\bar{c}} = m_{ii} P(\bar{C} | G_i G_i) = m_{ii} (1 - P(C | G_i G_i)) \end{cases}$$

Alors on a pour l'algorithme:

$$\delta^{(t)} = \frac{f^{(t)} f_i^{(t)}}{f^{(t)} f_i^{(t)} + (1 - f^{(t)}) f_i^{2(t)}} \quad \hat{m}_{ii}^c{}^{(t)} = m_{ii} \delta^{(t)} \quad \hat{m}_{ii}^{\bar{c}}{}^{(t)} = m_{ii} (1 - \delta^{(t)})$$

ÉTAPE M: maximiser l_c par rapport f et t_i

On a:

$$l_c(f, t_1, t_2, t_3) =$$

$$= \sum_i n_{ii}^c \log[f t_i] + \sum_i n_{ii}^{\bar{c}} \log[(1-f) t_i^2] + \sum_{i \neq j} n_{ij} \log[2(1-f) t_i t_j]$$

$$= \sum_i n_{ii}^c (\log[f] + \log[t_i]) + \sum_i n_{ii}^{\bar{c}} (\log[1-f] + 2 \log[t_i]) + \sum_{i \neq j} n_{ij} (\log[2] + \log[1-f] + \log[t_i t_j])$$

$$= \sum_i n_{ii}^c \log[f] + \left(\sum_i n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij} \right) \log[1-f] + \sum_{i \neq j} n_{ij} \log[2] + \sum_i (n_{ii}^c + 2 n_{ii}^{\bar{c}}) \log[t_i] + \sum_{i \neq j} n_{ij} \log[t_i t_j]$$

$$= \sum_i n_{ii}^c \log[f] + \left(\sum_i n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij} \right) \log[1-f] + K + \sum_i (n_{ii}^c + 2 n_{ii}^{\bar{c}}) \log[t_i] + \sum_{i \neq j} n_{ij} (\log[t_i] + \log[t_j])$$

$$= \sum_i n_{ii}^c \log[f] + \left(\sum_i n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij} \right) \log[1-f] + K + \sum_i (n_{ii}^c + 2 n_{ii}^{\bar{c}}) \log[t_i] + \sum_{i \neq j} n_{ij} \log[t_i] + \sum_{i \neq j} n_{ij} \log[t_j]$$

$$= \sum_i n_{ii}^c \log[f] + \left(\sum_i n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij} \right) \log[1-f] + K + \sum_i (n_{ii}^c + 2 n_{ii}^{\bar{c}}) \log[t_i] + \sum_{i \neq j} n_{ij} \log[t_i] + \sum_{i \neq j} n_{ij} \log[t_i]$$

$$= \sum_i n_{ii}^c \log[f] + \left(\sum_i n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij} \right) \log[1-f] + K + \sum_i (n_{ii}^c + 2 n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij}) \log[t_i]$$

* Maximiser en fonction de f :

On note:

$$l(f, t_1, t_2, t_3) = \sum_i n_{ii}^c \log[f] + \left(\sum_i n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij} \right) \log[1-f] + K + \sum_i (n_{ii}^c + 2 n_{ii}^{\bar{c}} + \sum_{i \neq j} n_{ij}) \log[t_i]$$

Donc

$$\frac{\partial l}{\partial f}(f, t_1, t_2, t_3) = \frac{\sum_i \hat{n}_{ii}^c}{f} - \frac{\sum_i \hat{n}_{ii}^{\bar{c}} + \sum_{i \neq j} \hat{n}_{ij}}{1-f}$$

Ceci nous donne:

$$\frac{\partial l}{\partial f}(\tilde{f}, t_1, t_2, t_3) = 0 \quad \Leftrightarrow \quad \left(\sum_i \hat{n}_{ii}^{\bar{c}} + \sum_{i \neq j} \hat{n}_{ij} \right) \tilde{f} = (1 - \tilde{f}) \sum_i \hat{n}_{ii}^c$$

$$\Leftrightarrow \left(\sum_i \hat{n}_{ii}^{\bar{c}} + \sum_{i \neq j} \hat{n}_{ij} + \sum_i \hat{n}_{ii}^c \right) \tilde{f} = \sum_i \hat{n}_{ii}^c$$

$$\Leftrightarrow \tilde{f} = \frac{\sum_i \hat{n}_{ii}^c}{N}$$

Donc on peut poser l'ALGORITHME:

$$f^{(e+1)} = \frac{\sum_i (\hat{n}_{ii}^c)^{(e)}}{N}$$

* Maximiser en fonction de p_i

On note:

$$l(p, p_1, p_2, p_3) = \sum_i m_{ii}^c \log[p] + \left(\sum_i m_{ii}^{\bar{c}} + \sum_{i \neq j} m_{ij} \right) \log[1-p] + K + \sum_i (m_{ii}^c + 2m_{ii}^{\bar{c}} + \sum_{i \neq j} m_{ij}) \log[p_i]$$

Avec $\sum_i p_i = 1$

Donc on note la lagrangien

$$\alpha(p_1, p_2, p_3, \lambda) = \sum_i (m_{ii}^c + 2m_{ii}^{\bar{c}} + \sum_{i \neq j} m_{ij}) \log[p_i] - \lambda (1 - \sum_i p_i)$$

On cherche λ :

$$\nabla \alpha(\tilde{p}_1, \tilde{p}_2, \tilde{p}_3, \lambda) = 0 \quad \Leftrightarrow \quad \begin{cases} \frac{\partial \alpha}{\partial p_1} = \lambda + \frac{\hat{m}_{11}^c + \hat{m}_{11}^{\bar{c}} + \hat{m}_{12} + \hat{m}_{13}}{\tilde{p}_1} = 0 \\ \frac{\partial \alpha}{\partial p_2} = \lambda + \frac{\hat{m}_{22}^c + \hat{m}_{22}^{\bar{c}} + \hat{m}_{12} + \hat{m}_{23}}{\tilde{p}_2} = 0 \\ \frac{\partial \alpha}{\partial p_3} = \lambda + \frac{\hat{m}_{33}^c + \hat{m}_{33}^{\bar{c}} + \hat{m}_{13} + \hat{m}_{23}}{\tilde{p}_3} = 0 \\ \tilde{p}_1 + \tilde{p}_2 + \tilde{p}_3 = 1 \end{cases}$$

$$\Leftrightarrow \quad \begin{cases} \tilde{p}_1 = \frac{N_1}{\lambda} \\ \tilde{p}_2 = \frac{N_2}{\lambda} \\ \tilde{p}_3 = \frac{N_3}{\lambda} \\ \frac{N_1}{\lambda} + \frac{N_2}{\lambda} + \frac{N_3}{\lambda} = 1 \end{cases} \quad \Leftrightarrow \quad \lambda = N_1 + N_2 + N_3$$

Donc on a les estimations

$$\begin{cases} \tilde{p}_1 = \frac{u_1}{\sum_i N_i} \\ \tilde{p}_2 = \frac{u_2}{\sum_i N_i} \\ \tilde{p}_3 = \frac{u_3}{\sum_i N_i} \end{cases}$$

Donc on peut poser l'ALGORITHME:

$$\forall i, p_i^{(t+1)} = \frac{N_i^{(t)}}{\sum_k N_k^{(t)}} \quad \text{avec} \quad N_i^{(t)} = \hat{m}_{ii}^{c(t)} + \hat{m}_{ii}^{\bar{c}(t)} + \sum_{i \neq j} m_{ij}$$

Test du rapport pour ϕ

On test

$$H_0: \phi = 0 \quad \text{et} \quad H_1: \phi > 0$$

On a la log-vraisemblance pour les données observées :

$$l(\phi, \pi_1, \pi_2, \pi_3) = \sum_{i < j} m_{ij} \log[2] + \sum_i m_{ii} \log[\phi \pi_i + (1-\phi) \pi_i^2] + \sum_{i < j} m_{ij} \log[(1-\phi) \pi_i \pi_j]$$

Sous H_0 , on a :

$$l(\phi, \pi_1, \pi_2, \pi_3) = \underbrace{\sum_{i < j} m_{ij} \log[2]}_{=K} + \sum_i m_{ii} \log[\pi_i^2] + \sum_{i < j} m_{ij} \log[\pi_i \pi_j] \\ + \sum_i \left(2m_{ii} + \sum_{i \neq j} m_{ij} \right) \log[\pi_i]$$

On pose $a_i = 2m_{ii} + \sum_{i \neq j} m_{ij}$.

Donc si on veut maximiser sous contrainte de $\sum_i \pi_i = 1$, on a le lagrangien :

$$l(\pi_1, \pi_2, \pi_3, \lambda) = \sum_i a_i \log[\pi_i] + \lambda \left(1 - \sum_i \pi_i \right)$$

On a

$$\begin{cases} \frac{\partial l}{\partial \pi_i} = \frac{a_i}{\pi_i} - \lambda = 0 \\ \pi_1 + \pi_2 + \pi_3 = 1 \end{cases} \Leftrightarrow \begin{cases} \tilde{\pi}_i = \frac{a_i}{\lambda} \\ \lambda = \sum_i a_i \end{cases}$$

Donc on a l'estimateur :

$$\tilde{\pi}_i = \frac{a_i}{\sum_i a_i} = \frac{2m_{ii} + \sum_{i \neq j} m_{ij}}{2n}$$

Ceci nous permet de introduire la STATISTIQUE DE TEST

$$\Lambda = 2 \left[l(\hat{\pi}, \hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3) - l(0, \tilde{\pi}_1, \tilde{\pi}_2, \tilde{\pi}_3) \right]$$

$\uparrow$ MAXIMUM DE VRAISEMBLANCE
avec EM

Pour le théorème de Wilks, on a :

$$\Lambda \xrightarrow{d} \chi^2_1$$

Correlation entre f et r_1

la corrélation est donnée par

$$\rho(f, r_1) = \frac{\text{Cov}[f, r_1]}{\sqrt{V[f]} \sqrt{V[r_1]}}$$