

INTRODUCTION À L'ALGORITHME EM

INFÉRENCE À PARTIR DE DONNÉES INCOMPLÈTES EN GÉNÉTIQUE
DES POPULATIONS

Lorenzo Segoni

TABLE DES MATIÈRES

1	Introduction	3
1.1	Deux grandes classes de maladies	3
2	Génétique des populations et estimation de fréquences alléliques	5
2.1	Transmission mendélienne : Première loi de Mendel	5
2.2	Loi de Hardy-Weinberg	5
	Les proportions de Hardy-Weinberg sont un équilibre	6
3	Résolution numérique d'un système non linéaire	12
3.1	Méthode de Newton-Raphson	12
	Méthode du score (Fisher scoring)	13
3.2	L'algorithme EM	13
	Vraisemblance des données complètes	13
	Une première idée : alterner les deux estimations	15
	Formalisation	15
	EM pour le locus <i>ABO</i>	16
	L'algorithme général	17
	Propriété de croissance	17
3.3	Comparaison des approches	18
	Estimation de la variance	18
4	Le bootstrap	19

INTRODUCTION

La **génétique** étudie la manière dont l'information héréditaire, portée par le génome, se transmet d'une génération à l'autre et s'exprime à travers les caractères des individus. Ce cours s'articulera autour de deux perspectives complémentaires.

La première approche est l'**épidémiologie génétique**. À l'échelle des populations (plutôt que de familles isolées), elle se consacre à la recherche des facteurs génétiques et des interactions gènes-environnement qui influencent le risque d'apparition d'une maladie ou modulent la distribution d'un phénotype.

La seconde approche, la **génétique des populations**, étudie quant à elle la distribution et la dynamique des variants génétiques (allèles, génotypes, haplotypes) au sein d'un groupe donné. Elle s'intéresse à la façon dont ces variants évoluent sous l'effet de diverses forces évolutives et démographiques, telles que la dérive génétique, la sélection naturelle, les migrations, les mutations et les accouplements non aléatoires.

I.1 DEUX GRANDES CLASSES DE MALADIES

Un phénotype pathologique peut relever de l'action d'un seul gène ou de la combinaison de plusieurs facteurs. Cette distinction est fondamentale, car elle conditionne la façon dont on modélise et estime le risque :

- Les **maladies monogéniques** résultent de la mutation d'un unique gène. Selon le mode de transmission, une seule copie mutée peut suffire à exprimer la maladie (mutation *dominante*), ou deux copies sont nécessaires (mutation *récessive*). Ces mutations confèrent une forte probabilité de développer la maladie; lorsque cette probabilité atteint 100%, on parle de *pénétrance complète*. On en connaît environ 5000 : elles sont rares ou très rares, souvent très graves, parfois létales.
- Les **maladies complexes**, ou multifactorielles, résultent au contraire de la combinaison de multiples facteurs à la fois génétiques et environnementaux, entre lesquels des interactions sont possibles. Plus fréquentes en population, elles sont généralement moins graves que les maladies monogéniques. Les cancers, les diabètes, les maladies allergiques, cardiovasculaires, infectieuses ou psychiatriques en constituent autant d'exemples.

OÙ SE SITUE CE COURS

Ce cours se déploie à l'intersection de trois domaines :

- la **génétique mendélienne**, qui décrit la transmission au sein des familles et des pedigrees;

- la **génétique des populations**, qui s'intéresse aux fréquences, aux équilibres et aux modèles probabilistes associés;
- l'**épidémiologie génétique**, qui met en relation gènes et phénotypes (risque, traits).

Le fil rouge : Un même problème traverse ces trois domaines : on cherche à *estimer des paramètres populationnels* — fréquences alléliques, proportions de génotypes, etc. — alors même que l'on n'observe pas tout. Certaines quantités restent cachées (génotypes non déterminés, ancestries inconnues, . . .) et ne se lisent pas directement dans les données. C'est précisément ce terrain, celui de l'inférence à partir de *données incomplètes*, que l'algorithme EM permet d'aborder; il constituera le fil conducteur des séances à venir.

RAPPELS DE VOCABULAIRE

Avant d'aborder les modèles, fixons le vocabulaire de base. Les définitions qui suivent constituent les briques élémentaires sur lesquelles reposeront tous les objets manipulés par la suite.

Définition 1.1. — **Génome** ensemble du matériel génétique d'un individu.

Exemple humain : 46 molécules d'ADN, soit 23 paires de chromosomes.

- **ADN** double hélice composée de nucléotides — A, C, G, T.

Exemple humain : environ 3 milliards de paires de bases.

- **Chromosomes** structures portant l'ADN.

Exemple humain : 22 paires d'autosomes et 1 paire de chromosomes sexuels (XX ou XY).

- **Gène** portion d'ADN portant une information, le plus souvent codante.
- **Locus** position (adresse) d'un élément sur le génome.
- **Polymorphisme** variation observée à un locus; chaque version possible est appelée un **allèle**.

Exemples : SNP, microsatellites, insertions/délétions, CNV, . . .

GÉNÉTIQUE DES POPULATIONS ET ESTIMATION DE FRÉQUENCES ALLÉLIQUES

2.1 TRANSMISSION MENDÉLIENNE : PREMIÈRE LOI DE MENDEL

Considérons un locus autosomal. Chaque individu y porte deux allèles, l'un d'origine maternelle et l'autre d'origine paternelle. Lors de la reproduction, chaque parent transmet à sa descendance l'un de ses deux allèles, tiré au hasard et de façon équiprobable.

L'idée directrice est la suivante : c'est précisément le caractère aléatoire de la transmission qui permet de relier les *fréquences alléliques* aux *fréquences génotypiques* dans la population.

2.2 LOI DE HARDY-WEINBERG

Plaçons-nous sous un ensemble d'hypothèses idéalisées :

- population d'effectif illimité,
- non soumise à la sélection
- exempte de mutation.

Sous ces conditions, deux propriétés remarquables apparaissent :

- d'une part, les fréquences alléliques demeurent constantes au fil des générations;
- d'autre part, si les accouplements sont panmictiques (aléatoires), les fréquences génotypiques se déduisent directement des fréquences alléliques et restent elles aussi constantes.

Considérons un locus A/B avec $p_A + p_B = 1$.

Fréquences génotypiques en fonction des fréquences alléliques.

$$\mathbb{P}(AA) = p_A^2, \quad \mathbb{P}(AB) = 2p_A p_B, \quad \mathbb{P}(BB) = p_B^2.$$

Fréquences alléliques en fonction des fréquences génotypiques.

Si l'on observe les effectifs N_{AA} , N_{AB} , N_{BB} dans un échantillon de taille N , alors

$$p_A = \frac{2N_{AA} + N_{AB}}{2N} = p_{AA} + \frac{1}{2}p_{AB}, \quad p_B = 1 - p_A.$$

Exemple 2.1. Considérons un locus polymorphique à trois allèles possibles : A , B et O .

On dénombre six génotypes : AA , AO , AB , BB , BO et OO . Les allèles

A et B sont codominants tandis que O est récessif, ce qui conduit à quatre phénotypes observables :

- phénotype A : génotypes AA ou AO ;
- phénotype B : génotypes BB ou BO ;
- phénotype AB : génotype AB ;
- phénotype O : génotype OO .

Plus généralement, on considère un locus polymorphique à k allèles codominants.

Traitons le cas $k = 2$: deux allèles A et B , de fréquences respectives p_A et p_B avec $p_A + p_B = 1$, donnant trois génotypes possibles AA , AB et BB .

On peut alors se poser les questions suivantes : quelle est la probabilité qu'un père transmette l'allèle A ? Qu'une mère transmette l'allèle A ? Et quelles sont, par suite, les probabilités des génotypes AA , BB et AB ?

LES PROPORTIONS DE HARDY-WEINBERG SONT UN ÉQUILIBRE

Supposons une population idéale. Les fréquences génotypiques de la première génération sont

$$\mathbb{P}_{AA} = p_A^2, \quad \mathbb{P}_{AB} = 2p_A p_B, \quad \mathbb{P}_{BB} = p_B^2.$$

Que deviennent-elles à la deuxième génération? Sous panmixie, on recense les croisements parentaux, leur fréquence et la loi de transmission à l'enfant :

Parents	Fréquence	$P_{\text{enfant}}(AA)$	$P_{\text{enfant}}(AB)$	$P_{\text{enfant}}(BB)$
$AA \times AA$	$\mathbb{P}_{AA}^2$	1	0	0
$AA \times AB$	$2\mathbb{P}_{AA}\mathbb{P}_{AB}$	$\frac{1}{2}$	$\frac{1}{2}$	0
$AA \times BB$	$2\mathbb{P}_{AA}\mathbb{P}_{BB}$	0	1	0
$AB \times AB$	$\mathbb{P}_{AB}^2$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$
$AB \times BB$	$2\mathbb{P}_{AB}\mathbb{P}_{BB}$	0	$\frac{1}{2}$	$\frac{1}{2}$
$BB \times BB$	$\mathbb{P}_{BB}^2$	0	0	1

En sommant les contributions de chaque croisement, on vérifie que les fréquences génotypiques de la génération 2 coïncident avec celles de la génération 1 : la distribution de Hardy-Weinberg est bien un point fixe du mécanisme de reproduction.

Exemple 2.2 (Locus lié au sexe). Considérons un locus bi-allélique A/B porté par le chromosome X . Les femmes (XX) présentent les génotypes AA , AB ou BB , tandis que les hommes (XY) ne portent qu'un seul allèle, A ou B . On note

- f_n la fréquence de A chez les femmes à la génération n ;
- m_n la fréquence de A chez les hommes à la génération n .

Supposons autant de femmes que d'hommes dans la population. Quelle est la proportion initiale de l'allèle A , notée p_0 ? Avec $N_F = N_M = N/2$, les femmes portant deux chromosomes X et les hommes un seul, on obtient

$$\begin{aligned} N_A(0) &= 2f_0 \cdot \frac{N}{2} + m_0 \cdot \frac{N}{2}, \\ N_T &= 2 \cdot \frac{N}{2} + \frac{N}{2} = \frac{3N}{2}, \\ p_0 &= \frac{2f_0 + m_0}{3}. \end{aligned}$$

Qu'en est-il de p_n ? Calculons d'abord p_1 . Un homme hérite son unique chromosome X de sa mère; une femme hérite chacun de ses deux chromosomes X d'un de ses deux parents, avec la même probabilité. On en déduit les relations de récurrence

$$m_n = f_{n-1} \quad (n \geq 1), \quad f_n = \frac{f_{n-1} + m_{n-1}}{2} \quad (n \geq 1).$$

Il vient alors

$$p_1 = \frac{2f_1 + m_1}{3} = \frac{2f_0 + m_0}{3} = p_0,$$

de sorte que la fréquence allélique reste inchangée d'une génération à l'autre.

On peut préciser ce comportement en montrant que f_n converge vers p :

$$\begin{aligned} f_n - p &= \frac{1}{2}f_{n-1} + \frac{1}{2}m_{n-1} - \frac{3}{2}p + \frac{1}{2}p \\ &= \frac{1}{2}f_{n-1} + \frac{1}{2}m_{n-1} - \frac{3}{2}\left(\frac{2}{3}f_{n-1} + \frac{1}{3}m_{n-1}\right) + \frac{1}{2}p \\ &= -\frac{1}{2}(f_{n-1} - p). \end{aligned}$$

La convergence est donc géométrique :

$$f_n - p = \left(-\frac{1}{2}\right)^n (f_0 - p).$$

Exemple 2.3 (Locus MN : estimation directe). Considérons le locus diallélique M/N , à trois génotypes M/M , M/N et N/N . Les allèles M et N étant codominants, les trois phénotypes MM , MN et NN sont directement observables. On dispose d'un échantillon de 6129 individus :

ALLÉLIQUES			
Échantillon	N_{MM}	N_{MN}	N_{NN}
Nombre observé	1787	3039	1303
Nombre attendu	1783,8	3045,4	1299,8
Proportion attendue	0,291	0,497	0,212

Posons $a = N_{MM}$, $b = N_{MN}$, $c = N_{NN}$, avec $a + b + c = n$. On souhaite estimer p_M et p_N , sous la contrainte $p_M + p_N = 1$. Sous l'équilibre de Hardy–Weinberg,

$$\mathbb{P}(MM) = p_M^2, \quad \mathbb{P}(MN) = 2p_M p_N, \quad \mathbb{P}(NN) = p_N^2.$$

Quelle est la probabilité de tirer un individu MM ? Deux individus MM ? Deux MM et un MN ? En prolongeant ce raisonnement, on obtient la densité $f(a, b, c)$. Chaque individu appartient à l'une des trois catégories MM , MN , NN , de probabilités respectives p_M^2 , $2p_M p_N$, p_N^2 . La probabilité d'observer l'échantillon (a, b, c) est donc

$$L(p_M) = \binom{n}{a, b, c} (p_M^2)^a (2p_M p_N)^b (p_N^2)^c, \quad \binom{n}{a, b, c} = \frac{n!}{a! b! c!}.$$

Comme $p_N = 1 - p_M$, on peut exprimer L , puis la log-vraisemblance ℓ , en fonction du seul paramètre p_M :

$$\begin{aligned} \ell(p_M) &= \log L(p_M) \\ &= a \log(p_M^2) + b \log(2p_M p_N) + c \log(p_N^2) + \text{const} \\ &= 2a \log(p_M) + b \log(2p_M(1 - p_M)) + 2c \log(1 - p_M) + \text{const}. \end{aligned}$$

En dérivant,

$$\ell'(p_M) = \frac{2a}{p_M} + \frac{b}{p_M} - \frac{b}{1 - p_M} - \frac{2c}{1 - p_M},$$

puis en résolvant $\ell'(p_M) = 0$, on aboutit à l'estimateur du maximum de vraisemblance

$$\hat{p}_M = \frac{2a + b}{2n}, \quad \hat{p}_N = 1 - \hat{p}_M.$$

Avec les données $a = 1787$, $b = 3039$, $c = 1303$ et $n = 6129$, on obtient

$$\hat{p}_M = \frac{2a + b}{2n} \approx 0,539, \quad \hat{p}_N \approx 0,461.$$

Sous l'équilibre de Hardy–Weinberg, la méthode du maximum de vraisemblance est donc immédiate et coïncide avec la méthode de comptage des gènes (les fréquences alléliques déduites des fréquences génotypiques).

Exemple 2.4 (Locus ABO : données incomplètes). Revenons au locus ABO , à trois allèles A, B, O et six génotypes AA, AO, AB, BB, BO, OO . Les allèles A et B sont codominants, O est récessif, ce qui produit quatre phénotypes observables A, B, AB, O selon la correspondance suivante :

Génotype	Phénotype
AA, AO	A
BB, BO	B
AB	AB
OO	O

Contrairement au locus MN , les génotypes ne sont pas tous observables et certains phénotypes sont ambigus : on observe les phénotypes, mais pas directement les génotypes. C'est là toute la difficulté.

Prenons un échantillon de taille $n = 521$:

Phénotype	A	B	AB	O
Effectif	186	38	13	284

On cherche à estimer $\theta = (p_A, p_B, p_O)$ à partir des phénotypes. Posons :

- le paramètre $\theta = (p_A, p_B, p_O)$ avec $p_A + p_B + p_O = 1$;
- les données observées (phénotypes) $Y = (n_A, n_B, n_{AB}, n_O)$ avec $n = n_A + n_B + n_{AB} + n_O$;
- les données cachées (génotypes) $Z = (n_{AA}, n_{AO}, n_{BB}, n_{BO}, n_{AB}, n_{OO})$ avec $n = \sum_g n_g$;
- les contraintes de cohérence $n_{AA} + n_{AO} = n_A, n_{BB} + n_{BO} = n_B, n_{AB} = n_{AB}$ et $n_{OO} = n_O$.

Sous l'équilibre de Hardy–Weinberg,

$$\mathbb{P}(A) = p_A^2 + 2p_A p_O, \quad \mathbb{P}(B) = p_B^2 + 2p_B p_O, \quad \mathbb{P}(AB) = 2p_A p_B, \quad \mathbb{P}(O) = p_O^2.$$

Pour $Y = (n_A, n_B, n_{AB}, n_O)$, la vraisemblance des données observées est

$$\begin{aligned} L(\theta) &= \binom{n}{n_A, n_B, n_{AB}, n_O} \mathbb{P}^{n_A}(A) \mathbb{P}^{n_B}(B) \mathbb{P}^{n_{AB}}(AB) \mathbb{P}^{n_O}(O) \\ &= \binom{n}{n_A, n_B, n_{AB}, n_O} (p_A^2 + 2p_A p_O)^{n_A} (p_B^2 + 2p_B p_O)^{n_B} (2p_A p_B)^{n_{AB}} (p_O^2)^{n_O}. \end{aligned}$$

La log-vraisemblance des données observées vaut, à une constante près,

$$\ell(\theta) = n_A \log(p_A^2 + 2p_A p_O) + n_B \log(p_B^2 + 2p_B p_O) + n_{AB} \log(2p_A p_B) + n_O \log(p_O^2),$$

sous la contrainte $p_A + p_B + p_O = 1$. En posant $p_O = 1 - p_A - p_B$, on obtient

$$\begin{aligned}\ell(p_A, p_B) &= n_A \log(p_A^2 + 2p_A(1 - p_A - p_B)) \\ &\quad + n_B \log(p_B^2 + 2p_B(1 - p_A - p_B)) \\ &\quad + n_{AB} \log(2p_A p_B) \\ &\quad + n_O \log((1 - p_A - p_B)^2).\end{aligned}$$

Les équations du maximum de vraisemblance sont alors $\frac{\partial \ell}{\partial p_A} = 0$ et $\frac{\partial \ell}{\partial p_B} = 0$: il s'agit d'un système non linéaire couplé, sans solution fermée explicite.

Détaillons le calcul. Partons de

$$\ell(p_A, p_B) = n_A \log(g_A) + n_B \log(g_B) + n_{AB} \log(2p_A p_B) + n_O \log(p_O^2),$$

avec $p_O = 1 - p_A - p_B$, $g_A = p_A^2 + 2p_A p_O$ et $g_B = p_B^2 + 2p_B p_O$. En tenant compte de $\partial p_O / \partial p_A = \partial p_O / \partial p_B = -1$, les dérivées utiles sont

$$\begin{aligned}\frac{\partial g_A}{\partial p_A} &= \frac{\partial g_B}{\partial p_B} = 2p_O, \\ \frac{\partial g_A}{\partial p_B} &= -2p_A, \\ \frac{\partial g_B}{\partial p_A} &= -2p_B, \\ \frac{\partial}{\partial p_A} \log(p_O^2) &= \frac{\partial}{\partial p_B} \log(p_O^2) = -\frac{2}{p_O}.\end{aligned}$$

On en déduit

$$\begin{aligned}\frac{\partial \ell}{\partial p_A} &= n_A \frac{2p_O}{g_A} - n_B \frac{2p_B}{g_B} + \frac{n_{AB}}{p_A} - \frac{2n_O}{p_O}, \\ \frac{\partial \ell}{\partial p_B} &= n_B \frac{2p_O}{g_B} - n_A \frac{2p_A}{g_A} + \frac{n_{AB}}{p_B} - \frac{2n_O}{p_O}.\end{aligned}$$

En remplaçant $p_O = 1 - p_A - p_B$ et en notant

$$g_A = p_A^2 + 2p_A(1 - p_A - p_B), \quad g_B = p_B^2 + 2p_B(1 - p_A - p_B),$$

les équations du maximum de vraisemblance deviennent

$$\begin{aligned}n_A \frac{2(1 - p_A - p_B)}{g_A} - n_B \frac{2p_B}{g_B} + \frac{n_{AB}}{p_A} - \frac{2n_O}{1 - p_A - p_B} &= 0, \\ n_B \frac{2(1 - p_A - p_B)}{g_B} - n_A \frac{2p_A}{g_A} + \frac{n_{AB}}{p_B} - \frac{2n_O}{1 - p_A - p_B} &= 0.\end{aligned}$$

Difficultés principales. Les termes $\log(p_A^2 + 2p_Ap_O)$ et $\log(p_B^2 + 2p_Bp_O)$ contiennent des sommes; celles-ci proviennent de l'ambiguïté génotypique (AA/AO et BB/BO).

Il en résulte plusieurs obstacles :

- les équations du maximum de vraisemblance (dérivées et contrainte) forment un système non linéaire couplé;
- il est impossible d'isoler analytiquement p_A ou p_B : il n'existe pas de formule explicite simple pour $(\hat{p}_A, \hat{p}_B, \hat{p}_O)$;
- contrairement au locus MN (génotypes observés), on ne peut pas « compter directement » les allèles.

RÉSOLUTION NUMÉRIQUE D'UN SYSTÈME NON LINÉAIRE

L'exemple du locus ABO nous a laissés devant un obstacle : les équations du maximum de vraisemblance y forment un système non linéaire couplé, dépourvu de solution explicite. Pour estimer $\hat{\theta} = (\hat{p}_A, \hat{p}_B, \hat{p}_O)$, il faut donc recourir à des méthodes numériques. Plusieurs familles s'offrent à nous :

- les méthodes de **Newton** ou du **score**, qui exploitent les dérivées de la log-vraisemblance;
- les méthodes de **point fixe**, qui reformulent le problème sous la forme $\theta = \Phi(\theta)$;
- les méthodes d'**optimisation numérique générale**, qui maximisent directement ℓ .

Ces approches sont efficaces, mais elles partagent plusieurs fragilités :

- une forte **dépendance à l'initialisation**;
- un risque de **convergence vers un maximum local** plutôt que global;
- une possible **instabilité numérique**, notamment lorsque la hessienne est mal conditionnée.

L'objectif est donc de trouver une méthode plus stable, qui tire parti de la structure probabiliste du modèle plutôt que de traiter la log-vraisemblance comme une fonction quelconque à optimiser.

3.1 MÉTHODE DE NEWTON-RAPHSON

On cherche à annuler le gradient de la log-vraisemblance, c'est-à-dire à résoudre

$$\nabla \ell(\theta) = 0.$$

Définition 3.1. La méthode de **Newton-Raphson** construit une suite d'itérés

$$\theta^{(k+1)} = \theta^{(k)} - [\nabla^2 \ell(\theta^{(k)})]^{-1} \nabla \ell(\theta^{(k)}),$$

où $\nabla \ell$ désigne le vecteur score et $\nabla^2 \ell$ la matrice hessienne.

Retenons ses principales caractéristiques :

- elle utilise à la fois le gradient (score) et la matrice hessienne;
- sa convergence est quadratique au voisinage du maximum;
- elle peut se révéler instable lorsque l'initialisation est éloignée de la solution.

MÉTHODE DU SCORE (FISHER SCORING)

On peut construire une variante de la méthode de Newton-Raphson en remplaçant la hessienne observée par sa valeur moyenne.

Définition 3.2. La **méthode du score** substitue à la hessienne observée l'information de Fisher attendue :

$$\theta^{(k+1)} = \theta^{(k)} + \mathcal{I}^{-1}(\theta^{(k)}) \nabla \ell(\theta^{(k)}),$$

où l'information de Fisher est définie par

$$\mathcal{I}(\theta) = -\mathbb{E}[\nabla^2 \ell(\theta)].$$

Cette variante présente deux atouts :

- elle est souvent un peu plus stable que la méthode de Newton ;
- elle conserve une convergence quadratique au voisinage du maximum.

3.2 L'ALGORITHME EM

Les méthodes de Newton et du score attaquent directement l'équation $\nabla \ell(\theta) = 0$, au prix d'un gradient et d'une hessienne parfois délicats à manier. L'algorithme EM (*Expectation–Maximization*) suit une tout autre stratégie : au lieu de dériver la log-vraisemblance des données observées, il exploite la structure à **données cachées** du modèle. L'idée de départ est une remarque simple sur le locus *ABO* : *si l'on connaissait les génotypes*, l'estimation redeviendrait aussi facile que pour le locus *MN* — un simple comptage d'allèles. Le seul obstacle est l'information manquante ; c'est précisément ce qu'EM est conçu pour contourner.

VRAISEMBLANCE DES DONNÉES COMPLÈTES

Exemple 3.1 (Locus *ABO* — vraisemblance des données complètes). Supposons un instant que l'on observe les effectifs génotypiques $n_{AA}, n_{AO}, n_{BB}, n_{BO}, n_{AB}, n_{OO}$. Sous l'équilibre de Hardy–Weinberg,

$$\begin{aligned} \mathbb{P}(AA) &= p_A^2, & \mathbb{P}(AO) &= 2p_A p_O, \\ \mathbb{P}(BB) &= p_B^2, & \mathbb{P}(BO) &= 2p_B p_O, \\ \mathbb{P}(AB) &= 2p_A p_B, & \mathbb{P}(OO) &= p_O^2. \end{aligned}$$

Pour $Z = (n_{AA}, n_{AO}, n_{BB}, n_{BO}, n_{AB}, n_{OO})$, la vraisemblance des données **complètes** s'écrit

$$L_c(\theta) = \binom{n}{n_{AA}, n_{AO}, n_{BB}, n_{BO}, n_{AB}, n_{OO}} \prod_g \mathbb{P}(g)^{n_g},$$

où le produit porte sur les six génotypes g . La log-vraisemblance complète vaut alors, à une constante près,

$$\ell_c(\theta) = \text{const} + \sum_g n_g \log \mathbb{P}(g),$$

soit, en explicitant chaque terme,

$$\begin{aligned} \ell_c(\theta) = \text{const} &+ n_{AA} \log(p_A^2) + n_{AO} \log(2p_A p_O) \\ &+ n_{BB} \log(p_B^2) + n_{BO} \log(2p_B p_O) \\ &+ n_{AB} \log(2p_A p_B) + n_{OO} \log(p_O^2). \end{aligned}$$

Le point crucial : il n'y a **plus de somme à l'intérieur des logarithmes**. Les termes quadratiques sont linéarisés, exactement comme pour le locus MN . La maximisation redevient donc immédiate.

Deux directions complémentaires. De cette vraisemblance complète découlent deux calculs élémentaires, inverses l'un de l'autre.

- **Si les génotypes étaient connus**, on estimerait les fréquences alléliques par comptage :

$$\hat{p}_A = \frac{2n_{AA} + n_{AO} + n_{AB}}{2n}, \quad \hat{p}_B = \frac{2n_{BB} + n_{BO} + n_{AB}}{2n}, \quad \hat{p}_O = 1 - \hat{p}_A - \hat{p}_B.$$

- **Si les fréquences alléliques étaient connues**, on estimerait la répartition des génotypes ambigus. Sous Hardy-Weinberg, un individu de phénotype A est AA ou AO ; conditionnellement à ce phénotype,

$$\mathbb{P}(AA \mid A, \theta) = \frac{p_A^2}{p_A^2 + 2p_A p_O}, \quad \mathbb{P}(AO \mid A, \theta) = \frac{2p_A p_O}{p_A^2 + 2p_A p_O},$$

d'où les effectifs attendus

$$\hat{n}_{AA} = n_A \cdot \mathbb{P}(AA \mid A, \theta), \quad \hat{n}_{AO} = n_A - \hat{n}_{AA},$$

et de même pour BB/BO à partir de n_B .

Aucune des deux directions n'est directement exploitable seule (chacune suppose connu ce que l'on cherche justement à estimer). Mais que se passe-t-il si l'on *alterne* ces deux étapes ?

UNE PREMIÈRE IDÉE : ALTERNER LES DEUX ESTIMATIONS

L'algorithme naturel est le suivant :

1. partir d'une valeur initiale $(p_A^{(0)}, p_B^{(0)}, p_O^{(0)})$;
2. calculer les effectifs génotypiques attendus (première direction);
3. mettre à jour les fréquences alléliques par comptage (seconde direction);
4. répéter jusqu'à convergence.

Appliquons-le aux données $n_A = 186, n_B = 38, n_{AB} = 13, n_O = 284$ ($n = 521$), en partant de l'initialisation neutre $(p_A^{(0)}, p_B^{(0)}, p_O^{(0)}) = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$.

Répartition initiale (étape E). Comme $\mathbb{P}(AA \mid A) = p_A / (p_A + 2p_O) = \frac{1}{3}$ à l'initialisation,

$$\hat{n}_{AA}^{(0)} = 186 \cdot \frac{1}{3} = 62, \quad \hat{n}_{AO}^{(0)} = 124, \quad \hat{n}_{BB}^{(0)} = 38 \cdot \frac{1}{3} \approx 12,7, \quad \hat{n}_{BO}^{(0)} \approx 25,3.$$

Mise à jour (étape M).

$$p_A^{(1)} \approx 0,250, \quad p_B^{(1)} \approx 0,061, \quad p_O^{(1)} \approx 0,688.$$

En itérant, les fréquences se stabilisent rapidement :

k	$p_A^{(k)}$	$p_B^{(k)}$	$p_O^{(k)}$
0	0,3333	0,3333	0,3333
1	0,2500	0,0611	0,6889
2	0,2185	0,0505	0,7311
3	0,2142	0,0502	0,7357

Cette procédure, construite de façon intuitive, est l'algorithme EM. Elle repose sur trois ingrédients :

- des **données observées** : les phénotypes;
- des **données cachées** : les génotypes;
- une **alternance** : compléter en moyenne, puis maximiser (mettre à jour).

FORMALISATION

Définition 3.3. L'**algorithme EM** est une méthode itérative d'estimation du maximum de vraisemblance en présence de données cachées. Chaque itération enchaîne deux étapes.

- **Étape E (Espérance).** Aux paramètres courants $\theta^{(k)}$, reconstruire ce que l'on n'observe pas : combien de $AA, AO, \dots$ sont plausibles étant donné les phénotypes (n_A, n_B, n_{AB}, n_O) ?

- **Étape M (Maximisation).** En traitant ces données cachées comme si elles étaient connues (remplacées par leur espérance), mettre à jour θ par maximisation : $\theta^{(k+1)} \leftarrow$ meilleure valeur de θ pour ces données « complétées ».

On distingue donc :

- les données observées $Y = (n_A, n_B, n_{AB}, n_O)$;
- les données complètes (Y, Z) , où $Z = (n_{AA}, n_{AO}, n_{BB}, n_{BO}, n_{AB}, n_{OO})$ est le comptage génotypique.

L'idée directrice est que travailler avec la vraisemblance des données complètes est souvent bien plus simple que directement avec celle des données observées. On introduit à cet effet la fonction objectif de l'étape E.

Définition 3.4. La fonction Q est l'espérance de la log-vraisemblance complète, conditionnellement aux données observées et aux paramètres courants :

$$Q_k(\theta) = \mathbb{E}_{\theta^{(k)}}[\ell_c(\theta) \mid Y].$$

Comme $\ell_c(\theta)$ est linéaire en les comptages n_g ,

$$Q_k(\theta) = \text{const} + \sum_g \mathbb{E}_{\theta^{(k)}}[n_g \mid Y] \log \mathbb{P}(g).$$

En pratique, on remplace chaque n_g par son espérance $\hat{n}_g^{(k)}$ calculée à l'étape E :

$$\begin{aligned} Q_k(\theta) = \text{const} &+ \hat{n}_{AA}^{(k)} \log(p_A^2) + \hat{n}_{AO}^{(k)} \log(2p_A p_O) + \hat{n}_{AB}^{(k)} \log(2p_A p_B) \\ &+ \hat{n}_{BB}^{(k)} \log(p_B^2) + \hat{n}_{BO}^{(k)} \log(2p_B p_O) + \hat{n}_{OO}^{(k)} \log(p_O^2). \end{aligned}$$

EM POUR LE LOCUS ABO

Étape E : génotypes attendus. À l'itération k , on calcule les effectifs attendus des seuls génotypes ambigus. Conditionnellement au phénotype A :

$$\mathbb{E}[n_{AA} \mid A, \theta^{(k)}] = n_A \cdot \frac{(p_A^{(k)})^2}{(p_A^{(k)})^2 + 2p_A^{(k)} p_O^{(k)}}, \quad \mathbb{E}[n_{AO} \mid A, \theta^{(k)}] = n_A - \mathbb{E}[n_{AA} \mid A, \theta^{(k)}].$$

De même pour le phénotype B (BB contre BO). Les phénotypes AB et O ne sont pas ambigus et ne demandent aucun calcul.

Étape M : mise à jour des fréquences alléliques. Une fois les effectifs génotypiques remplacés par leurs espérances, on cherche $\theta^{(k+1)}$ qui maximise $Q_k(\theta)$ sous la contrainte $p_A + p_B + p_O = 1$. La solution est, une fois encore, une simple mise à jour par comptage :

$$\begin{aligned} p_A^{(k+1)} &= \frac{2\hat{n}_{AA}^{(k)} + \hat{n}_{AO}^{(k)} + n_{AB}}{2n}, \\ p_B^{(k+1)} &= \frac{2\hat{n}_{BB}^{(k)} + \hat{n}_{BO}^{(k)} + n_{AB}}{2n}, \\ p_O^{(k+1)} &= 1 - p_A^{(k+1)} - p_B^{(k+1)}. \end{aligned}$$

L'ALGORITHME GÉNÉRAL

Définition 3.5 (Schéma général de l'algorithme EM). **Entrée** : données observées Y , initialisation $\theta^{(0)}$, tolérance ε .

1. Fixer $k = 0$.
2. **Étape E** : calculer $Q_k(\theta) = \mathbb{E}_{\theta^{(k)}}[\log p(Y, Z \mid \theta) \mid Y]$.
3. **Étape M** : poser $\theta^{(k+1)} = \arg \max_{\theta} Q_k(\theta)$.
4. **Arrêt** si $\|\theta^{(k+1)} - \theta^{(k)}\| < \varepsilon$; sinon $k \leftarrow k + 1$ et retour à l'étape 2.

PROPRIÉTÉ DE CROISSANCE

L'intérêt fondamental d'EM tient à une garantie de monotonie.

Remarque 3.1. Le choix de $\theta^{(k+1)}$ tel que $Q_k(\theta^{(k+1)}) \geq Q_k(\theta^{(k)})$ entraîne

$$\ell(\theta^{(k+1)}) \geq \ell(\theta^{(k)}),$$

où ℓ désigne la log-vraisemblance des *données observées*. Autrement dit, celle-ci augmente ou reste constante à chaque itération : EM produit une suite **monotone croissante** de valeurs de la log-vraisemblance.

Cette propriété explique la grande stabilité numérique d'EM. Elle ne garantit toutefois pas :

- la convergence vers le maximum **global** (on peut se retrouver piégé dans un maximum local);
- une convergence **rapide** (la progression peut être lente).

Nous disposons désormais de deux grandes familles de méthodes pour résoudre le problème du locus *ABO* : Newton et le score d'un côté, EM de l'autre. Il reste à les mettre en regard.

3.3 COMPARAISON DES APPROCHES

Il est éclairant de mettre en regard les méthodes de type Newton et l'algorithme EM, car elles incarnent deux compromis opposés.

Newton / score	Algorithme EM
Convergence rapide, quadratique près du maximum	Convergence monotone, mais souvent lente
Peut diverger si l'initialisation est mauvaise	Augmente la vraisemblance à chaque itération
Requiert le gradient et la hessienne	Requiert une espérance conditionnelle
Délicate si la vraisemblance est compliquée	Simple si la vraisemblance complète est simple
Sensible aux problèmes numériques	Très stable numériquement

En un mot : **EM échange la vitesse contre la stabilité**. Là où Newton converge rapidement mais peut diverger, EM progresse plus lentement tout en garantissant, à chaque étape, une vraisemblance qui ne décroît jamais.

ESTIMATION DE LA VARIANCE

Les méthodes de Newton et du score possèdent un avantage précieux sur EM. Évaluée au maximum de vraisemblance $\hat{\theta}$, l'inverse de la matrice d'information (observée ou attendue),

$$\mathcal{I}^{-1}(\hat{\theta}),$$

fournit une estimation de la matrice de covariance de l'estimateur. On peut ainsi quantifier directement la précision du MLE.

Pour EM, la situation est moins confortable :

- l'algorithme fournit bien le maximum de vraisemblance $\hat{\theta}$;
- mais il ne produit pas directement la matrice d'information, et donc pas d'estimation immédiate de la variance.

Se pose alors une question naturelle : *comment estimer la variance de $\hat{\theta}$ lorsqu'on a recours à EM* ? C'est l'objet du chapitre suivant.

LE BOOTSTRAP

Une réponse possible consiste à contourner entièrement le calcul de la matrice d'information, en approchant la loi de l'estimateur par rééchantillonnage.

Principe 4.1 (Bootstrap). *L'idée est d'approcher la distribution de l'estimateur par rééchantillonnage. La procédure est la suivante :*

- on génère B échantillons bootstrap par tirage avec remise à partir des données observées;
- pour chaque échantillon b , on recalcule l'estimateur $\hat{\theta}^{(b)}$ à l'aide de l'algorithme EM;
- on approche la variance de $\hat{\theta}$ par la variance empirique des $\hat{\theta}^{(b)}$.

Formellement, si $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(B)}$ désignent les estimateurs obtenus sur les B échantillons bootstrap, on estime la variance par

$$\hat{V}[\hat{\theta}] = \frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{(b)} - \bar{\theta})^2, \quad \bar{\theta} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{(b)}.$$

On obtient de la sorte une estimation empirique de la précision du MLE, sans jamais dériver la log-vraisemblance.

Il existe deux grandes variantes de la méthode, selon que l'on fait ou non confiance au modèle.

Définition 4.1 (Bootstrap empirique et paramétrique). Le **bootstrap empirique** :

- procède par tirage avec remise à partir des données observées;
- ne fait aucune hypothèse sur le modèle;
- recalcule $\hat{\theta}^{(b)}$ (via EM) sur chaque échantillon tiré.

Le **bootstrap paramétrique** :

- suppose le modèle correct;
- simule de nouvelles données selon la loi ajustée $f(\cdot | \hat{\theta})$;
- recalcule $\hat{\theta}^{(b)}$ (via EM) sur chaque échantillon simulé.

Ces deux variantes se distinguent sur plusieurs plans :

	Empirique	Paramétrique
Hypothèse sur le modèle	Non	Oui
Robustesse	Plus robuste	Dépend du modèle
Variance estimée	Plus large	Souvent plus petite

Bilan 4.1 (Bootstrap). Les avantages :

- ne nécessite pas le calcul de la matrice d'information;
- facile à implémenter;
- parfaitement compatible avec l'algorithme EM.

Les limites :

- un coût de calcul élevé, puisque EM doit être répété B fois;
- une possible instabilité lorsque l'échantillon est de petite taille;
- une sensibilité aux problèmes de convergence d'EM.

Introduction à l'algorithme EM

Ce cours introduit l'algorithme EM (Expectation–Maximization) à travers un fil conducteur issu de la génétique des populations : l'estimation de fréquences alléliques à partir de données incomplètes. Après un rappel des notions de génétique et de la loi de Hardy–Weinberg, on montre comment l'ambiguïté entre génotypes et phénotypes (locus ABO) rend le maximum de vraisemblance analytiquement inaccessible. On compare alors les méthodes numériques classiques (Newton–Raphson, score de Fisher) à l'algorithme EM, qui exploite la structure à variables latentes du modèle, avant d'aborder l'estimation de la variance de l'estimateur par bootstrap. Le fil conducteur reste l'inférence à partir de données incomplètes, des fondements probabilistes jusqu'à la mise en œuvre.