

Projet Lynx

Lorenzo Segoni

Introduction et Analyse Qualitative

Présentation des données

Les lynx du Canada occupent une place centrale dans l'écosystème nord-américain. Leur population, suivie depuis près de deux siècles à travers les registres de piégeage pour le commerce des fourrures, constitue l'un des jeux de données les plus célèbres en écologie et en statistique.

Si la dynamique des populations peut être modélisée de manière déterministe par des systèmes de type **Lotka–Volterra**, cette approche nécessite la connaissance des populations de proies (lièvres). L'intérêt des modèles de séries temporelles réside dans leur capacité à capturer la structure interne de la série de manière univariée, en exploitant l'autocorrélation des données.

Ce projet analyse la série annuelle (**frequency** = 1) du nombre de lynx piégés entre 1821 (**start**) et 1934 (**end**), avec un total de **114 observations**. Après une analyse qualitative et une décomposition de la série, nous comparerons différents modèles stochastiques afin de sélectionner celui qui offre le meilleur ajustement et les prévisions les plus fiables.

```
# Données lynx
lynx_ts <- ts(lynx, start = 1821, end = 1934, frequency = 1)
lynx_ts
```

Time Series:

Start = 1821

End = 1934

Frequency = 1


[1]	269	321	585	871	1475	2821	3928	5943	4950	2577	523	98	184	279	409
[16]	2285	2685	3409	1824	409	151	45	68	213	546	1033	2129	2536	957	361
[31]	377	225	360	731	1638	2725	2871	2119	684	299	236	245	552	1623	3311
[46]	6721	4254	687	255	473	358	784	1594	1676	2251	1426	756	299	201	229
[61]	469	736	2042	2811	4431	2511	389	73	39	49	59	188	377	1292	4031

```
[76] 3495  587  105  153  387  758 1307 3465 6991 6313 3794 1836  345  382  808
[91] 1388 2713 3800 3091 2985 3790  674   81   80  108  229  399 1132 2432 3574
[106] 2935 1537  529  485  662 1000 1590 2657 3396
```

Analyse exploratoire

La première étape de notre étude consiste à observer l'allure générale de la série temporelle brute afin de confirmer nos premières intuitions.

```
# Représentation de la série brute
autoplot(lynx_ts) +
  labs(title = "Série : Nombre de lynx piégés", x = "Années", y = "Nombre de lynx") +
  theme_minimal()
```



Une caractéristique flagrante de cette série est sa **forte structure cyclique**. On dénombre environ 11 cycles sur la période totale, ce qui correspond à une périodicité d'environ **10 ans**. Cette observation est en parfaite adéquation avec les cycles biologiques connus des populations de lynx.

De plus, nous ne constatons aucune tendance globale sur le long terme. La série semble fluctuer autour d'une moyenne constante, ce qui nous permet de poser l'hypothèse d'une **stationnarité en moyenne**.


Enfin, l'amplitude des pics est irrégulière : certains cycles atteignent 6000 individus tandis que d'autres plafonnent sous la barre des 4000.

Analyse des fonctions d'autocorrélation

Pour identifier la structure stochastique de la série `lynx_ts`, nous étudions les fonctions d'autocorrélation totale (**ACF**) et partielle (**PACF**).

Corrélogramme (ACF)


```
# Plot Acf  
ggAcf(lynx_ts) + labs(title = "ACF de la série")
```



La courbe présente une **forme sinusoïdale amortie**. Cette décroissance, bien que lente, confirme la stationnarité de la série tout en soulignant une très forte dépendance temporelle. La présence d'un pic positif significatif au **Lag 10** confirme la périodicité observée lors de l'analyse visuelle. Le pic négatif marqué au **Lag 5** indique une corrélation inverse : en moyenne, un maximum de population est suivi d'un minimum environ 5 ans plus tard.

Corrélogramme partiel (PACF)

```
# Plot Pacf  
ggPacf(lynx_ts) + labs(title = "PACF de la série")
```



On observe deux pics très significatifs aux Lag 1 et Lag 2. Au-delà du deuxième retard, les coefficients chutent brusquement et entrent dans la zone de non-significativité (même si l'on trouve certaines exceptions isolées). Cette structure est la signature caractéristique d'un processus **Auto-Régressif d'ordre 2**, soit un modèle **AR(2)**.

Décomposition de la série temporelle

Cette étape vise à isoler les différentes composantes de la série (tendance et cycle) afin de mieux comprendre sa structure interne et de valider nos hypothèses de stationnarité.


Extraction de la tendance par moyenne mobile

Pour isoler l'évolution de fond, nous utilisons un filtre de moyenne mobile d'ordre 10, ce qui correspond à la durée d'un cycle complet observé.

```
# Extraction de la tendance par moyenne mobile
lynx.filtered <- ma(lynx_ts, order = 10, centre = TRUE)

autoplot(lynx_ts, series = "Série Originale") +
  autolayer(lynx.filtered, series = "Tendance", color = "turquoise") +
  labs(title = "Extraction de la tendance par lissage",
       x = "Temps", y = "Nombre de lynx") +
  theme_minimal()
```

Extraction de la tendance par lissage




On constate que le filtre réussit parfaitement sa mission : il « gomme » les pics et les creux extrêmes pour ne garder que l'évolution de fond de la population. La tendance n'est pas une droite parfaite, mais elle reste comprise dans une bande stable (entre 1000 et 3000 individus). Cela confirme visuellement que la série ne présente pas de dérive ou de tendance déterministe marquée sur le long terme, ce qui confirme l'hypothèse de stationnarité en moyenne.

Analyse de la série détrendée

En soustrayant la tendance obtenue par moyenne mobile de la série originale, nous obtenons la série detrendée `lynx.dt`. Cette transformation permet d'isoler la composante cyclique pure.

```
# Série détrendée
lynx.dt <- lynx_ts - lynx.filtered

autoplot(lynx.dt) +
  labs(title = "Composante cyclique et résiduelle",
        y = "Écart à la tendance") +
  theme_minimal()
```



Bien que la série soit désormais centrée sur zéro, on observe toujours une forte variabilité de l'amplitude des cycles. Cette instabilité de la variance (**hétéroscédasticité**) suggère que le retrait de la tendance seul est insuffisant pour normaliser la série. Cela justifie l'intérêt d'une transformation logarithmique pour stabiliser l'amplitude des fluctuations.

Analyse harmonique (Séries de Fourier)

Pour tester si le cycle peut être modélisé de façon déterministe, nous utilisons une régression harmonique basée sur les termes de Fourier.

```
# On force la fréquence à 10 pour capturer le cycle décennal
lynx_cycle_ts <- ts(lynx_ts, frequency = 10)

K <- 5 # T = 10 = 2*K
XREG <- fourier(lynx_cycle_ts, K)

lynx.season <- tslm(lynx_cycle_ts ~ XREG - 1)
summary(lynx.season)
```

Call:

```
tslm(formula = lynx_cycle_ts ~ XREG - 1)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-801.4	779.6	1267.9	2108.7	6344.6

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
XREGS1-10	-326.68	279.89	-1.167	0.245793
XREGC1-10	-1130.56	282.52	-4.002	0.000117 ***
XREGS2-10	75.31	280.09	0.269	0.788551
XREGC2-10	158.39	282.50	0.561	0.576203
XREGS3-10	-84.47	280.08	-0.302	0.763565
XREGC3-10	-22.95	282.52	-0.081	0.935410
XREGS4-10	93.49	280.09	0.334	0.739203
XREGC4-10	-66.24	282.50	-0.234	0.815075
XREGC5-10	35.24	198.91	0.177	0.859737

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2122 on 105 degrees of freedom

Multiple R-squared: 0.1464, Adjusted R-squared: 0.07326

F-statistic: 2.001 on 9 and 105 DF, p-value: 0.04618

L'examen des coefficients montre que seul le terme **XREGC1-10** (cosinus du premier ordre) est hautement significatif ($p < 0.001$). Cela confirme mathématiquement que la périodicité de 10 ans est une structure fondamentale de la série.

Cependant, le coefficient de détermination ajusté est très faible ($R_{adj}^2 = 0.066$). Cette valeur indique que les fonctions trigonométriques déterministes n'expliquent que **6,6 %** de la variance totale de la population.

L'échec d'une modélisation purement déterministe (Fourier) pour capturer l'essentiel de la variance démontre que la « mémoire » de la série est bien plus complexe qu'une simple oscillation régulière.

Cela justifie le passage à une modélisation stochastique de type **ARMA** sur les résidus, afin de capturer l'autocorrélation temporelle que les filtres classiques ne parviennent pas à absorber.

Modélisation Stochastique : L'approche ARMA

Stratégie de validation

Avant d'ajuster nos modèles, nous adoptons une approche de **validation croisée**.

Nous divisons la série en deux : **85 %** pour l'apprentissage et **15 %** pour le test. Ce découpage permet de conserver environ 17 années pour la validation, un horizon supérieur au cycle de 10 ans, ce qui est indispensable pour vérifier si le modèle capture bien la périodicité et non un simple “bruit” passager.

```
#Cross Validation
n <- length(lynx_ts)
train_end <- floor(0.85 * n)
time_idx <- time(lynx_ts)
lynx.train <- window(lynx_ts, end = time_idx[train_end])
lynx.test  <- window(lynx_ts, start = time_idx[train_end + 1])
```

Choisir des modèles : Le compromis entre biais et variance

L'analyse de la PACF nous a orientés vers une structure $AR(2)$. Pour confirmer cette intuition, nous mettons en compétition les structures candidates jusqu'à $ARMA(2,2)$. Nous arbitrons entre deux philosophies : la **parcimonie** (chercher le modèle le plus simple, privilégié par la *BIC*) et la **flexibilité** (chercher le meilleur ajustement, privilégié par l'*AIC*).

On choisit $\lambda = 0$, ce qui applique une transformation logarithmique à la série afin de stabiliser la variance avant l'estimation des modèles ARMA.

```
#Modélisation ARMA
fit_ar1    <- Arima(lynx.train, order = c(1, 0, 0), lambda = 0)
fit_arma11 <- Arima(lynx.train, order = c(1, 0, 1), lambda = 0)
fit_arma12 <- Arima(lynx.train, order = c(1, 0, 2), lambda = 0)
fit_ar2    <- Arima(lynx.train, order = c(2, 0, 0), lambda = 0)
fit_arma21 <- Arima(lynx.train, order = c(2, 0, 1), lambda = 0)
fit_arma22 <- Arima(lynx.train, order = c(2, 0, 2), lambda = 0)

df_comp <- data.frame(
  Modèle = c("AR(1)", "ARMA(1,1)", "ARMA(1,2)", "AR(2)", "ARMA(2,1)", "ARMA(2,2)"),
  AIC     = c(fit_ar1$aic, fit_arma11$aic, fit_arma12$aic, fit_ar2$aic, fit_arma21$aic, fit_arma22$aic),
  BIC     = c(fit_ar1$bic, fit_arma11$bic, fit_arma12$bic, fit_ar2$bic, fit_arma21$bic, fit_arma22$bic),
  LogV    = c(fit_ar1$loglik, fit_arma11$loglik, fit_arma12$loglik, fit_ar2$loglik, fit_arma21$loglik, fit_arma22$loglik),
)

df_comp
```

	Modèle	AIC	BIC	LogV
1	AR(1)	231.8168	239.5098	-112.90840
2	ARMA(1,1)	185.6732	195.9306	-88.83660
3	ARMA(1,2)	182.9990	195.8207	-86.49950

```

4      AR(2) 158.2767 168.5341 -75.13837
5 ARMA(2,1) 158.4192 171.2410 -74.20962
6 ARMA(2,2) 160.3269 175.7130 -74.16346

```

Les modèles **AR(1)** et **ARMA(1,p)** sont nettement distancé, confirmant qu'un seul retard ne suffit pas à décrire un cycle. Le modèle **ARMA(2,2)** affiche l' *AIC* le plus bas, tandis que l' **AR(2)** reste le meilleur de la parcimonie selon le *BIC*.

C'est pour ça que on va choisir le modèle **AR(2)**.

Analyse du modèle AR(2)

On va analyser le modèle **AR(2)** :

```
summary(fit_ar2)
```

```

Series: lynx.train
ARIMA(2,0,0) with non-zero mean
Box Cox transformation: lambda= 0

```

Coefficients:

```

          ar1      ar2      mean
          1.3826 -0.7364  6.7005
s.e.  0.0671   0.0669  0.1511

```

```

sigma^2 = 0.2815:  log likelihood = -75.14
AIC=158.28   AICc=158.72   BIC=168.53

```

Training set error measures:

```

              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 185.7505 908.4072 568.9046 -14.63313 46.52065 0.6698554 0.04618491

```

```
coeftest(fit_ar2)
```

z test of coefficients:

```

          Estimate Std. Error z value Pr(>|z|)
ar1          1.382568   0.067120  20.598 < 2.2e-16 ***
ar2         -0.736385   0.066874 -11.011 < 2.2e-16 ***
intercept    6.700456   0.151052  44.359 < 2.2e-16 ***

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


L'alternance des signes des coefficients AR est importante car elle traduit mathématiquement le cycle étudié. Le test de Wald montre que la structure AR est le moteur du modèle.

Validation prédictive

On va comparer le modele prédit et `lynx.test`

```
#Prevision AR(2) contre test
fit_ar2 <- forecast(fit_ar2, h = length(lynx.test))

autoplot(fit_ar2) +
  autolayer(lynx.test, series = "Réalité", color = "red") +
  theme_minimal()
```



Le modèle réussit le test de la phase : il “sent” quand la population doit monter ou descendre. Cependant, il échoue sur l’amplitude. Étant stationnaire, le modèle tend à revenir vers sa moyenne dès que l’horizon s’éloigne, là où la nature produit des pics brutaux.

```
# Calcul de l'erreur sur le Test Set
accuracy(fit_ar2, lynx.test)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	185.7505	908.4072	568.9046	-14.63313	46.52065	0.6698554
Test set	408.2198	1272.4620	968.1012	-143.78223	199.19699	1.1398884

	ACF1	Theil's U
Training set	0.04618491	NA
Test set	0.64796983	2.963122

Le modèle fonctionne correctement sur l'entraînement, mais se dégrade fortement sur le test. Cela indique un surapprentissage (overfitting) et une mauvaise capacité de généralisation.

Bilan de la modélisation

L'utilisation d'un modèle **AR(2)** s'avère être le meilleur compromis. Il permet de respecter la cyclicité, même si l'erreur de prediction presente quelque faiblesse dans l'intervalle de confiance, comme vu dans l'accuracy du set test.

Arbitrage entre modèles stationnaires et intégrés

Une question centrale en série temporelle est celle de la différenciation. Bien que la série semble stationnaire autour d'une moyenne, nous testons si un modèle intégré (**ARIMA** avec $d = 1$ et $d = 2$) apporte un meilleur ajustement qu'un modèle stationnaire.

```
# Modèle stationnaire AR(2)
fit_d0 <- Arima(lynx.train, order = c(2, 0, 0), lambda = 0)

# Modèle stationnaire ARMA(2,2)
fit_d1 <- Arima(lynx.train, order = c(2, 0, 2), lambda = 0)

# Modèle intégré (première différence)
fit_d2 <- Arima(lynx.train, order = c(2, 1, 2), lambda = 0)

# Modèle intégré (deuxieme différence)
fit_d3 <- Arima(lynx.train, order = c(2, 2, 2), lambda = 0)

# Comparaison
df_int <- data.frame(
  Modèle = c("AR(2,2)", "ARMA(2,2)", "ARIMA(2,1,2)", "ARIMA(2,2,2)"),
  AIC     = c(fit_d0$aic, fit_d1$aic, fit_d2$aic, fit_d3$aic),
  BIC     = c(fit_d0$bic, fit_d1$bic, fit_d2$bic, fit_d3$bic),
  LogV    = c(fit_d0$loglik, fit_d1$loglik, fit_d2$loglik, fit_d3$loglik)
)

df_int
```


	Modèle	AIC	BIC	LogV
1	AR(2,2)	158.2767	168.5341	-75.13837
2	ARMA(2,2)	160.3269	175.7130	-74.16346
3	ARIMA(2,1,2)	153.5516	166.3210	-71.77579
4	ARIMA(2,2,2)	169.1265	181.8430	-79.56326

Le tableau met en évidence la supériorité du modèle avec $d = 1$. Ce modèle affiche les critères AIC et BIC les plus faibles, ainsi que la meilleure log-vraisemblance. L'introduction d'une première différence permet donc d'améliorer significativement le compromis entre la qualité d'ajustement aux données et la parcimonie du modèle.

Diagnostic des résidus du modèle final

Pour valider définitivement l'**ARIMA(2,1,2)**, il est indispensable de s'assurer que ses résidus se comportent comme un bruit blanc. Si c'est le cas, cela signifie que toute la structure de la série temporelle a bien été capturée par le modèle et qu'il ne reste aucune information exploitable dans les erreurs.

```
checkresiduals(fit_d2)
```



Ljung-Box test

```
data: Residuals from ARIMA(2,1,2)
Q* = 14.175, df = 6, p-value = 0.02775
```

```
Model df: 4. Total lags used: 10
```

La série des résidus oscille de manière relativement constante autour de zéro. Il n'y a plus de tendance visible ni de variance explosive, confirmant que la moyenne et la variance ont été globalement stabilisées par les transformations préalables.

L'histogramme montre une distribution relativement symétrique qui s'approche d'une loi normale, rendant l'hypothèse de normalité des résidus tout à fait acceptable.

Visuellement, la quasi-totalité des autocorrélations se situe à l'intérieur des intervalles de confiance, à l'exception d'un léger dépassement (autour du retard 12). Cependant, le test formel affiche une p-value de 0.02775. Étant inférieure au seuil de 5%, ce test indique qu'il subsiste une autocorrélation significative dans les erreurs.

Donc si on prend en considération tout ce que l'on obtient de ce chapitre final est que le modèle **ARIMA(2,1,2)** est un bon modèle pour modéliser cette série.

Prévisions finales et Conclusion

Pour clore cette étude, nous ajustons notre modèle final **ARIMA(2,1,2)** sur l'intégralité de la série temporelle (1821-1934) afin de maximiser l'information disponible pour l'estimation des paramètres.

L'objectif est de projeter la dynamique de la population de lynx sur un horizon de 15 ans. Ce choix dépasse volontairement la durée d'un cycle biologique unique (environ 10 ans) afin de vérifier la capacité du modèle à engager la répétition du cycle suivant de manière cohérente.


```
# Ajustement sur la série complète
fit_final_real <- Arima(lynx_ts, order = c(2, 1, 2), lambda = 0)

# Préviation sur 15 ans
prev_finale <- forecast(fit_final_real, h = 15)

# Graphique final en échelle réelle
autoplot(prev_finale) +
  labs(title = "Préviation finale de la population de Lynx (1935-1949)",
        subtitle = "Modèle ARIMA(2,1,2)",
        x = "Années", y = "Nombre de lynx") +
  theme_minimal()
```

Prévision finale de la population de Lynx (1935–1949)

Modèle ARIMA(2,1,2)



Analyse de la projection

À partir de 1934, la population de lynx entre clairement dans une phase de déclin. Le modèle prévoit correctement que cette baisse se poursuit jusqu'à atteindre un minimum autour de 1938. Ce qui est encore plus intéressant, c'est qu'il anticipe aussi le début d'une nouvelle phase de croissance vers 1944-1945. Cela montre que le modèle **ARIMA** arrive bien à reproduire le caractère cyclique de la population, grâce à ses composantes autorégressives et moyennes mobiles qui «mémorisent» les oscillations passées.

Le pic prévu autour de 1945 (courbe bleue) est cependant plus faible et plus lissé que les pics réellement observés dans l'histoire. On observe aussi que l'incertitude augmente fortement au moment du pic prévu. Cette incertitude vient du fait que les pics de population présentent une variance très élevée. Les intervalles de confiance deviennent alors multiplicatifs : plus la population peut potentiellement monter haut, plus l'incertitude s'élargit. Cela reflète bien la réalité écologique du lynx : lors des phases d'abondance, la population peut varier énormément, ce qui rend le sommet des pics particulièrement imprévisible.

Conclusion générale

Cette étude a mis en évidence l'efficacité des modèles fondés sur les séries temporelles pour analyser des données écologiques complexes. En passant d'un modèle stationnaire simple à un modèle **ARIMA(2,1,2)**, il a été possible de saisir à la fois l'évolution de la variance et la

structure de dépendance temporelle (cycle de dix ans) caractérisant la dynamique du lynx du Canada.

Même si la prévision de l'amplitude exacte des pics de population est fortement incertaine en raison de la variabilité naturelle, le modèle fournit une projection mathématiquement et biologiquement cohérente. Les modèles **ARIMA** apparaissent ainsi comme une approche pertinente pour modéliser cette population sans nécessiter d'informations supplémentaires comme le suivi de populations des lièvres ou d'autres facteurs écologiques.